

Biostatistics Program1

Task 1

目录

1 Problem Statement.....	2
2 Notation.....	2
3 EM derivation.....	2
4 Simulating data.....	4
5 Result.....	5
5.1 运行实验.....	5
5.2 用于分析的实验.....	5
6 Analysis.....	6
6.1 初值设置.....	6
6.2 迭代结果.....	7
6.3 后续分析.....	7
7 Code.....	7

1 Problem Statement

已知袋中有 A 种硬币 a 枚，B 种硬币 b 枚，两种硬币除了抛掷出现正反面的概率不同以外没有其他区别，随机从中取出 1 枚，抛掷 10 次，有放回的取出 5 次，记录每次抛掷的结果得到如上数据，下求从袋中取出一枚硬币，该硬币为 i 种硬币的概率以及两种硬币各自抛掷正反面的概率的极大似然估计。其中， $i=a, b$ 。

2 Notation

符号说明

符号	说明
x_i	第 i 次取出硬币时，抛掷十次中正面朝上的次数。
π_k	从袋中随机取出一枚硬币，该硬币为 i 种硬币的概率， $k = a, b$ 。
θ_k	抛掷一枚 i 种硬币时，正面朝上的概率， $k = a, b$ 。
z_i	第 i 次取出的硬币种类，当硬币为 A 种时，该值为 0，否则为 1。

- 注：1. 当符号没有下标时，表示相应的向量表述。
2. 当符号为大写字母时表示相应随机变量，小写时表示相应的样本数据。
3. 带上标符号表示迭代次数为上标时，该符号代表的参数值。

3 EM derivation

目标:

$$\begin{aligned} \begin{pmatrix} \hat{\theta} \\ \hat{\pi} \end{pmatrix} &= \underset{\theta, \pi}{\operatorname{argmax}} \log P(X; \theta, \pi) = \underset{\theta, \pi}{\operatorname{argmax}} \log \left(\prod_i P(X_i = x_i; \theta, \pi) \right) \\ &= \underset{\theta, \pi}{\operatorname{argmax}} \sum_i \log P(x_i; \theta, \pi) = \underset{\theta, \pi}{\operatorname{argmax}} \sum_i \log \sum_{z_i} P(X_i = x_i, Z_i = z_i; \theta, \pi) \end{aligned}$$

步骤:

① 随机化或根据专业知识等先验选取相应初始参数，记 $\text{ite}=0$ （迭代次数），转步二。

② E-step:

$$\begin{aligned} E_z(\ln P(X, Z; \theta, \pi)) &= \sum_Z \ln(P(X, Z; \theta, \pi)) P(Z | X; \theta^{(\text{ite})}, \pi^{(\text{ite})}) \\ &= \sum_Z \sum_i \ln(P(X_i, Z; \theta, \pi)) P(Z | X_i; \theta^{(\text{ite})}, \pi^{(\text{ite})}) \end{aligned}$$

已知：

$$\begin{aligned}
P(X_i = x_i | Z_i = z_i; \theta, \pi) &= C_n^{x_i} (\theta_A^{(1-z_i)} \theta_B^{z_i})^{x_i} (1 - \theta_A^{(1-z_i)} \theta_B^{z_i})^{10-x_i} \\
P(Z_i = 0) &= \pi_A \quad P(Z_i = 1) = \pi_B \\
P(X_i = x_i, Z_i = z_i; \theta, \pi) &= P(Z_i = z_i; \theta, \pi) P(X_i = x_i | Z_i = z_i; \theta, \pi) \\
P(Z_i = z_i | X_i = x_i; \theta, \pi) &= \frac{P(X_i = x_i, Z_i = z_i; \theta, \pi)}{P(X_i = x_i; \theta, \pi)} \\
&= \frac{P(X_i = x_i, Z_i = z_i; \theta, \pi)}{P(X_i = x_i, Z_i = 0; \theta, \pi) + P(X_i = x_i, Z_i = 1; \theta, \pi)}
\end{aligned}$$

将已知代入 $E_z(\ln P(X, Z; \theta, \pi))$ ，转步 3。

③M-step

$$\begin{aligned}
\begin{pmatrix} \theta^{(ite+1)} \\ \pi^{(ite+1)} \end{pmatrix} &= \arg \max_{\theta, \pi} E_{Z; \theta^{(ite)}, \pi^{(ite)}} (\ln P(X, Z; \theta, \pi)) \\
&= \arg \max_{\theta, \pi} \sum_i (\ln(\pi_A C_n^{x_i} \theta_A^{x_i} (1 - \theta_A)^{10-x_i}) \\
&\quad \frac{\pi_A^{(ite)} C_n^{x_i} \theta_A^{(ite)x_i} (1 - \theta_A^{(ite)})^{10-x_i}}{\pi_A^{(ite)} C_n^{x_i} \theta_A^{(ite)x_i} (1 - \theta_A^{(ite)})^{10-x_i} + \pi_B^{(ite)} C_n^{x_i} \theta_B^{(ite)x_i} (1 - \theta_B^{(ite)})^{10-x_i}} \\
&\quad + \ln(\pi_B C_n^{x_i} \theta_B^{x_i} (1 - \theta_B)^{10-x_i}) \\
&\quad \frac{\pi_B^{(ite)} C_n^{x_i} \theta_B^{(ite)x_i} (1 - \theta_B^{(ite)})^{10-x_i}}{\pi_A^{(ite)} C_n^{x_i} \theta_A^{(ite)x_i} (1 - \theta_A^{(ite)})^{10-x_i} + \pi_B^{(ite)} C_n^{x_i} \theta_B^{(ite)x_i} (1 - \theta_B^{(ite)})^{10-x_i}})
\end{aligned}$$

对上式化简,可将 π_B 用 π_A 表示，并求极大值：

$$\frac{\partial E_z(\ln P(X, Z; \theta, \pi))}{\partial \pi_A} = 0$$

$$\frac{\partial E_z(\ln P(X, Z; \theta, \pi))}{\partial \theta_A} = 0$$

$$\frac{\partial E_z(\ln P(X, Z; \theta, \pi))}{\partial \theta_B} = 0$$

记 $\frac{\pi_A^{(ite)} C_n^{x_i} \theta_A^{(ite)^{x_i}} (1 - \theta_A^{(ite)})^{10 - x_i}}{\pi_A^{(ite)} C_n^{x_i} \theta_A^{(ite)^{x_i}} (1 - \theta_A^{(ite)})^{10 - x_i} + \pi_B^{(ite)} C_n^{x_i} \theta_B^{(ite)^{x_i}} (1 - \theta_B^{(ite)})^{10 - x_i}}$ 为 $\gamma_{iA}^{(ite)}$,

记 $\frac{\pi_B^{(ite)} C_n^{x_i} \theta_B^{(ite)^{x_i}} (1 - \theta_B^{(ite)})^{10 - x_i}}{\pi_A^{(ite)} C_n^{x_i} \theta_A^{(ite)^{x_i}} (1 - \theta_A^{(ite)})^{10 - x_i} + \pi_B^{(ite)} C_n^{x_i} \theta_B^{(ite)^{x_i}} (1 - \theta_B^{(ite)})^{10 - x_i}}$ 为 $\gamma_{iB}^{(ite)}$

$$\pi_A^{(ite+1)} = \frac{\sum_i \gamma_{iA}^{(ite)}}{\sum_i \gamma_{iA}^{(ite)} + \sum_i \gamma_{iB}^{(ite)}}$$

$$\pi_B^{(ite+1)} = \frac{\sum_i \gamma_{iB}^{(ite)}}{\sum_i \gamma_{iA}^{(ite)} + \sum_i \gamma_{iB}^{(ite)}}$$

$$\theta_A^{(ite+1)} = \frac{\sum_i \gamma_{iA}^{(ite)} x_i}{\sum_i \gamma_{iA}^{(ite)} x_i + \sum_i \gamma_{iA}^{(ite)} (10 - x_i)}$$

$$\theta_B^{(ite+1)} = \frac{\sum_i \gamma_{iB}^{(ite)} x_i}{\sum_i \gamma_{iB}^{(ite)} x_i + \sum_i \gamma_{iA}^{(ite)} (10 - x_i)}$$

计算出相应的参数，ite=ite+1，转步四。

④计算是否满足收敛，若是输出参数，若否转步 2。

4 Simulating data

实验 1:

在 r 中设定参数:

```
thetaa=0.4
thetab=0.4
pia=0.5
pib=1-pia
#generate data
set.seed(1234)
```

生成相应的数据 X= (2 4 4 4 6 2 4)

实验 2:

在 r 中设定参数:

```

thetaa=0.4
thetab=0.8
pia=0.6
pib=1-pia
#generate data
set.seed(1234)

```

生成相应的数据 $X = (9 \ 2 \ 4 \ 4 \ 4 \ 6 \ 5)$

5 Result

5.1 运行实验

经过多步迭代分别得到如下结果：

实验一：

初值：

π_A : 0.5 π_B : 0.5 θ_A : 0.4999 θ_B : 0.5

结果：

π_A : 0.5001285 π_B : 0.4998715 θ_A : 0.3714267 θ_B : 0.3714304

实验二：

初值：

π_A : 0.5 π_B : 0.5 θ_A : 0.4999 θ_B : 0.5

结果：

π_A : 0.8595305 π_B : 0.1404695 θ_A : 0.4189718 θ_B : 0.8941107

5.2 用于分析的实验

实验 1：分析初值设置

```

thetaa=0.4
thetab=0.8
pia=0.6
pib=1-pia
#generate data
set.seed(1234)
num_data=7#数据总个数

```

(1) 初值：

π_A : 0.5 π_B : 0.5 θ_A : 0.5 θ_B : 0.5

结果：

$\pi_A: 0.5$ $\pi_B: 0.5$ $\theta_A: 0.4857143$ $\theta_B: 0.4857143$

(2) 初值:

$\pi_A: 0.5$ $\pi_B: 0.5$ $\theta_A: 0.49$ $\theta_B: 0.5$

结果:

$\pi_A: 0.8595303$ $\pi_B: 0.1404697$ $\theta_A: 0.4189717$ $\theta_B: 0.8941104$

实验 2: 分析初值设置

```
thetaa=0.4
thetab=0.8
pia=0.6
pib=1-pia
#generate data
set.seed(1234)
```

(1) number_data=7

初值:

$\pi_A: 0.5$ $\pi_B: 0.5$ $\theta_A: 0.49$ $\theta_B: 0.5$

结果:

$\pi_A: 0.8595303$ $\pi_B: 0.1404697$ $\theta_A: 0.4189717$ $\theta_B: 0.8941104$

(2) number_data=2000

初值:

$\pi_A: 0.5$ $\pi_B: 0.5$ $\theta_A: 0.5$ $\theta_B: 0.5$

结果:

$\pi_A: 0.6021486$ $\pi_B: 0.3978514$ $\theta_A: 0.3952088$ $\theta_B: 0.7948334$

6 Analysis

6.1 初值设置

我们通过数次实验发现, 当我们令 $\pi_A = \pi_B$ 且 $\theta_A = \theta_B$ 时, 结果将会始终保持 $\pi_A = \pi_B$ 且 $\theta_A = \theta_B$, 我们分析 EM 算法的迭代公式发现由于 π_i 的迭代基于 θ_A 与 θ_B , 如果两者相同, π_k 将不会发生变化, 同样, 当 π_k 固定不变, θ_A 与 θ_B 也不会发生

变化。而只需将 π_A , π_B 设为不同的值, 或将 θ_A , θ_B 设为不同的值, 即使差别很小, 结果也往往能迭代到更为接近真实情况的值。我们可以认为 EM 算法利用了先验知识计算后验期望的最大似然, 而将 $\pi_A = \pi_B$ 且 $\theta_A = \theta_B$, 则可认为我们将 A、B 视为同一类, 先验即两者来自同一个总体, 因此后验期望也会认为他们来自同一总体。

6.2 迭代结果

我们可以看到上述部分结果并不精准, 但如果我们增大样本容量, 我们可以发现迭代误差会变得很小, 即使我们的先验偏差较大, 实验结果也能收敛到很接近预设初值的结果, EM 算法是利用已知的样本数据, 在先验的基础下求解参数的方法, 因此即使先验偏差较大, 但只要样本数据足够多且准确, 我们就可以得到较好的迭代结果, 但前提是先验不陷入某些 EM 算法的局限, 如 6.1 中分析的 EM 算法的先验为样本均来自同一总体, 则后验也将认为其来自同一总体。

6.3 后续分析

由于部分分析与 Task2 重合, 因此我们将这部分分析放到 Task2 中。

7 Code

```
#task 1

#set parameter
thetaa=0.4
thetab=0.8
pia=0.6
pib=1-pia
#generate data
set.seed(1234)
num_data=2000#数据总个数
num_data1=rbinom(1,num_data,pia)
set.seed(1234)
data1=rbinom(num_data1, 10, thetaa)
set.seed(1234)
data2=rbinom(num_data-num_data1,10,thetab)
data=c(data2,data1)
```

```
data_0=rep(10,time=num_data)
```

```
#em
```

```
Expect=function(param,data)#条件期望
```

```
{  
  params=param  
  a=1:params[1]  
  b=1:params[1]  
  for (i in 1:params[1]) {  
    di=data[i]  
    k=(params[2]*choose(10,di)*((params[3])^(di)*((1-params[3])^(10-di))))  
    l=((1-params[2])*choose(10,di)*((params[4])^(di))*((1-params[4])^(10-di)))  
    a[i]=k/(k+l)  
    b[i]=l/(k+l)  
  }  
  Ec=c(a,b)  
  return(c(a,b))  
}
```

```
EM=function(param,data)
```

```
{  
  #param 初始参数, data 数据  param[num_data,pia,thetaa,thetab]  
  num_cyc=10000  
  parameter=matrix(c(1:num_cyc*4),num_cyc,4,1)  
  #paramter=data.frame(paramter_matrix,colnames = c("num_data","pia","thetaa","thetab"))  
  Ec=Expect(param,data)  
  Ea=Ec[1:param[1]]  
  Eb=Ec[(param[1]+1):(2*(param[1]))]  
  parameter[1,1]=num_data  
  parameter[1,2]=sum(Ea)/(sum(Ea)+sum(Eb))  
  parameter[1,3]=data%%Ea/(data%%Ea+(data_0-data)%%Ea)  
  parameter[1,4]=data%%Eb/(data%%Eb+(data_0-data)%%Eb)  
  q=0  
  error=0.000001  
  for (i in 2:num_cyc) {
```



```

Ec=Expect(parameter[i-1,],data)
Ea=Ec[1:param[1]]
Eb=Ec[(param[1]+1):(2*(param[1]))]
parameter[i,1]=num_data
parameter[i,2]=sum(Ea)/(sum(Ea)+sum(Eb))
parameter[i,3]=data**Ea/(data**Ea+(data_0-data)**Ea)
parameter[i,4]=data**Eb/(data**Eb+(data_0-data)**Eb)
q=q+1

if(parameter[i,2]-parameter[i-1,2]<error)
{
    return(parameter[i,])
}
}
}

#main test
param=c(num_data,0.5,0.4,0.5)
parameter_fin=EM(param,data)
print(parameter_fin)

```